

Une histoire intellectuelle, sociale et politique

DE L'IA AUX LLMS

Cybernétique, contre-culture, capitalisme cognitif

Cours en quatre séances · 8 heures

Licence Sciences sociales

Avant-propos

Ce cours propose une histoire de l'intelligence artificielle pensée pour des étudiants en sciences sociales. Son ambition n'est pas de produire des spécialistes techniques, mais de fournir les outils intellectuels nécessaires pour comprendre ce que sont les grands modèles de langage (LLMs) qui occupent aujourd'hui l'espace public, comment ils fonctionnent, d'où ils viennent, et ce qu'ils nous disent du moment historique que nous traversons.

Le pari pédagogique est double. D'une part, il faut prendre la technique au sérieux : on ne peut pas critiquer ce qu'on ne comprend pas, et la sociologie des sciences nous rappelle que les artefacts techniques cristallisent des choix politiques, économiques et épistémologiques. D'autre part, il faut refuser le récit linéaire et héroïque que l'industrie elle-même produit sur son histoire. L'IA n'est pas tombée du ciel en novembre 2022 avec ChatGPT : elle est le produit d'une histoire longue, faite de bifurcations, d'oublis stratégiques, de continuités institutionnelles avec l'appareil militaire américain, mais aussi de rencontres improbables avec la contre-culture californienne.

Le plan suit quatre séances de deux heures chacune.

- **Séance 1.** Préhistoire de l'IA : la cybernétique comme science du contrôle (1943–1960).
- **Séance 2.** L'IA symbolique, ses échecs, et la contre-culture californienne (1960–1980).
- **Séance 3.** Le retour des réseaux de neurones et la révolution des données (1980–2017).
- **Séance 4.** Les LLMs : architecture, fonctionnement, et critique (2017–aujourd'hui).

Chaque séance peut être lue indépendamment, mais l'ordre proposé construit progressivement les concepts nécessaires à la compréhension finale des LLMs. Des encadrés techniques sont insérés à chaque fois qu'une notion mérite d'être expliquée précisément ; des encadrés "contexte" replacent les enjeux dans leur cadre politique et social.

Séance 1 — Préhistoire de l'IA

La cybernétique comme science du contrôle (1943–1960)

1.1. Le contexte : la science en guerre

Pour comprendre l'IA, il faut commencer par la Seconde Guerre mondiale. Cette période transforme radicalement le rapport entre sciences, État et industrie aux États-Unis. Le projet Manhattan, le radar, le décryptage allemand par Alan Turing à Bletchley Park, mais aussi les recherches sur les calculateurs balistiques constituent ce que l'historien Paul Edwards a appelé une "clôture du monde" : l'idée que la guerre, puis la guerre froide, peuvent être pensées comme des problèmes de calcul, de prédiction et de contrôle.

C'est dans ce contexte que naît la cybernétique. Le mot vient du grec *kubernêtês*, le pilote, le gouvernail. Norbert Wiener, mathématicien au MIT, travaille pendant la guerre sur la défense anti-aérienne : comment prédire la trajectoire d'un avion ennemi pour ajuster le tir ? Le problème pose une question fondamentale : un système (le canon) doit s'auto-corriger en fonction d'informations sur son environnement (la trajectoire de l'avion). C'est la naissance d'un concept central, celui de feedback, ou rétroaction.

Concept-clé : la rétroaction (feedback)

Un système rétroactif est un système qui ajuste son comportement en fonction des résultats de ses actions précédentes. Le thermostat est l'exemple canonique : il mesure la température (information), la compare à la consigne (objectif), et active ou désactive le chauffage (action). La cybernétique généralise cette idée à toutes sortes de systèmes — biologiques, mécaniques, sociaux. Wiener affirme qu'un être vivant et une machine guidée fonctionnent selon les mêmes principes : ils sont des *systèmes téléologiques*, c'est-à-dire orientés vers un but, capables de corriger leurs erreurs.

1.2. McCulloch et Pitts : le neurone formel (1943)

En 1943 paraît un article fondateur, signé par Warren McCulloch, neurophysiologiste, et Walter Pitts, jeune logicien autodidacte : « A Logical Calculus of the Ideas Immanent in Nervous Activity ». Leur thèse est radicale : on peut modéliser un neurone biologique comme une porte logique. Un neurone formel reçoit des entrées (excitation, inhibition), les somme, et émet un signal de sortie si un seuil est franchi.

L'enjeu philosophique est immense. Si la pensée se réduit à des opérations logiques, et si ces opérations peuvent être réalisées par des automates, alors la pensée elle-même peut être mécanisée. C'est l'acte de naissance simultané de deux courants qui domineront l'IA : le connexionnisme

(l'intelligence émerge de la connexion de nombreuses unités simples) et le computationnalisme (penser, c'est calculer).

« *Tout ce que peut faire le cerveau peut être fait par une machine de calcul.* » — Warren McCulloch, paraphrasant Pitts

1.3. Les conférences Macy : la cybernétique comme transdiscipline (1946–1953)

Entre 1946 et 1953, à New York, se tiennent dix conférences financées par la Josiah Macy Jr. Foundation. Y participent des figures qui structureront pour longtemps les sciences cognitives : Wiener, McCulloch, von Neumann, Margaret Mead, Gregory Bateson, Claude Shannon, Heinz von Foerster. La sociologue Céline Lafontaine a montré dans *L'Empire cybernétique* (2004) à quel point ces conférences sont un événement de civilisation : on y forge un langage commun pour parler du vivant, des machines, des sociétés et de l'esprit.

Trois apports majeurs en sortent. D'abord, la théorie de l'information de Claude Shannon (1948) : l'information est une grandeur mesurable, indépendante de son sens. C'est une rupture épistémologique majeure — le sens devient secondaire devant la transmission. Ensuite, la modélisation des systèmes vivants comme systèmes de traitement d'information : Bateson appliquera cela aux sociétés et aux familles, fondant une école de psychiatrie (l'École de Palo Alto). Enfin, l'idée que l'esprit, le cerveau et la machine sont commensurables, ce qui ouvre la voie à toute l'IA ultérieure.

Contexte : la cybernétique comme idéologie

La cybernétique n'est pas seulement une science, c'est aussi une vision du monde. Pour ses critiques (Lafontaine, Philippe Breton, Jean-Pierre Dupuy), elle porte une *ontologie informationnelle* : tout ce qui existe — atomes, gènes, neurones, marchés — est compris comme flux d'information. Cette vision a des affinités avec le néolibéralisme naissant : Hayek, économiste autrichien, conçoit le marché comme un système de traitement d'information distribué. La pensée systémique, née en milieu militaire, devient peu à peu la grammaire commune de la gestion, du management, de l'écologie et même de la psychothérapie.

1.4. Turing : la machine et le test (1936, 1950)

Alan Turing publie en 1936 un article qui définit ce qu'on appellera la machine de Turing : un dispositif théorique capable d'exécuter n'importe quel calcul descriptible par un algorithme. C'est le fondement mathématique de l'informatique. Pendant la guerre, il met en pratique ces idées à Bletchley Park pour casser le code allemand Enigma.

En 1950, dans « Computing Machinery and Intelligence », Turing pose la question : « les machines peuvent-elles penser ? ». Il la juge mal posée et la reformule en jeu d'imitation : si un interlocuteur humain ne peut distinguer, par échange textuel, une machine d'un humain, alors la question de savoir si la machine pense vraiment devient secondaire. C'est le fameux test de Turing — qu'on retrouvera comme référence implicite dans toute l'histoire des chatbots, jusqu'à ChatGPT.

Notons un point important pour des étudiants en sciences sociales : Turing était homosexuel, condamné en 1952 pour « indécence grossière », contraint à une castration chimique, et mort en 1954 dans des conditions qui restent débattues (suicide ou accident). Sa réhabilitation officielle par le Royaume-Uni date de 2009. L'histoire de l'IA est aussi une histoire de violences sociales infligées à ses pionniers.

1.5. Dartmouth 1956 : naissance officielle de l'IA

À l'été 1956, John McCarthy, Marvin Minsky, Claude Shannon et Nathaniel Rochester organisent au Dartmouth College un séminaire d'été. Dans la proposition de financement adressée à la Fondation Rockefeller, McCarthy forge le terme « artificial intelligence » — selon ses mots, pour se démarquer de la cybernétique de Wiener qu'il jugeait trop floue, et marquer un programme de recherche distinct, plus orienté vers la logique formelle et la résolution de problèmes.

« Nous proposons une étude de deux mois, à dix participants, sur l'intelligence artificielle. Cette étude est conduite sur l'hypothèse que tout aspect de l'apprentissage ou tout autre trait de l'intelligence peut en principe être décrit avec une telle précision qu'une machine peut être construite pour le simuler. » — Proposition de Dartmouth, 1955

Le séminaire ne produit aucune percée immédiate. Mais il marque une rupture institutionnelle : la naissance d'un champ autonome, l'IA, qui s'éloignera progressivement de la cybernétique de Wiener (orientée vers les systèmes biologiques et le feedback) pour se concentrer sur la manipulation symbolique. Cette bifurcation est cruciale pour la suite : pendant trente ans, l'IA dominante sera symbolique, et les réseaux de neurones — héritiers directs de McCulloch et Pitts — seront marginalisés.

1.6. Bilan et lectures

La séance dégage trois enseignements majeurs. Premièrement, l'IA naît dans un contexte militaire et technocratique : on ne peut comprendre ses développements ultérieurs sans tenir compte de ce financement initial (DARPA, Office of Naval Research). Deuxièmement, elle naît d'une convergence entre logique mathématique, neurophysiologie et théorie du contrôle, qui pose comme évidente une équivalence entre cerveau, esprit et machine. Troisièmement, elle se constitue, dès Dartmouth 1956, comme un champ qui choisit la voie symbolique contre la voie connexionniste — un choix dont nous payerons les conséquences pendant des décennies.

Lectures recommandées pour la séance 1

- Dupuy, Jean-Pierre (1994), *Aux origines des sciences cognitives*, La Découverte.
- Lafontaine, Céline (2004), *L'Empire cybernétique. Des machines à penser à la pensée machine*, Seuil.
- Breton, Philippe (1990), *La Tribu informatique*, Métailié.
- Edwards, Paul N. (1996), *The Closed World*, MIT Press.
- Turing, Alan (1950), « Computing Machinery and Intelligence », *Mind*, 59 (texte traduit en français disponible).

Séance 2 — L'IA symbolique et la contre-culture

Bifurcations, échecs, et alliances inattendues (1960–1980)

2.1. L'IA symbolique : penser, c'est manipuler des symboles

Dans les années 1960-1970, l'IA dominante est dite « symbolique » ou « bonne vieille IA » (GOFAI, Good Old-Fashioned AI, selon l'expression du philosophe John Haugeland). Son hypothèse fondatrice est formulée par Allen Newell et Herbert Simon en 1976 : un système physique de symboles a les moyens nécessaires et suffisants pour produire une action intelligente. Penser, c'est manipuler des symboles selon des règles formelles.

Concrètement, cela donne des programmes comme Logic Theorist (1956) qui démontre des théorèmes mathématiques, GPS (General Problem Solver, 1959) qui résout des problèmes en explorant des espaces d'états, ou Eliza (1966) de Joseph Weizenbaum, qui simule un psychothérapeute rogerien. Eliza est emblématique : c'est un système ridiculement simple — elle se contente de reformuler les phrases de l'utilisateur sous forme de questions — mais ses utilisateurs s'y attachent, lui prêtent une compréhension profonde. Weizenbaum, horrifié par ce phénomène, écrira en 1976 *Computer Power and Human Reason*, un ouvrage critique fondamental où il distingue ce qu'on peut faire avec des ordinateurs et ce qu'on devrait.

Concept technique : qu'est-ce qu'un système symbolique ?

Dans l'IA symbolique, la connaissance est représentée explicitement, sous forme de règles logiques. Par exemple : *SI animal a des plumes ET pond des œufs ALORS animal est un oiseau*. Le programme manipule ces règles pour déduire de nouvelles connaissances. C'est élégant, transparent (on peut auditer chaque inférence), mais cela suppose que toute connaissance puisse être formalisée — ce qui se révélera être l'angle mort fatal de cette approche.

2.2. Le premier hiver de l'IA (1974)

En 1974, le mathématicien britannique James Lighthill publie un rapport commandé par le gouvernement britannique. Sa conclusion est cinglante : l'IA n'a pas tenu ses promesses, ses succès se limitent à des « micro-mondes » artificiels, elle est incapable de passer à l'échelle des problèmes réels. Le financement public britannique s'effondre. Aux États-Unis, la DARPA réduit drastiquement les budgets. C'est le premier hiver de l'IA.

Pourquoi cet échec ? Plusieurs raisons. Les ordinateurs de l'époque sont trop lents et ont trop peu de mémoire. Mais surtout, les chercheurs sous-estiment massivement la difficulté de formaliser la connaissance ordinaire, ce que Hubert Dreyfus, philosophe à Berkeley nourri de phénoménologie

heideggérienne, dénonce depuis 1965. Dans *What Computers Can't Do* (1972), Dreyfus argumente que l'intelligence humaine n'est pas une affaire de règles explicites mais de savoir-faire incorporé, situé, contextuel. Il sera longtemps moqué par la communauté IA, avant d'être largement réhabilité.

2.3. La contre-culture californienne et le personal computing

Pendant que l'IA institutionnelle traverse son hiver, quelque chose d'autre se passe à quelques kilomètres de Stanford. Pour le comprendre, il faut entrer dans une histoire qui semble n'avoir aucun rapport : celle de la contre-culture américaine des années 1960-1970. C'est l'apport majeur de l'historien Fred Turner dans *From Counterculture to Cyberculture* (2006, traduit en français en 2012).

Dans les années 1960, deux contre-cultures coexistent en Californie. La New Left (gauche militante, antimilitariste, opposée à la guerre du Vietnam) descend dans la rue et conteste l'État. Mais une autre, que Turner appelle les New Communalists, fait sécession : elle quitte les villes pour fonder des communautés rurales (entre 1965 et 1972, environ 750 000 Américains rejoignent ces communes). Ce mouvement est antiétatique, antibureaucratique, mais pas antitechnologique : il croit que des technologies appropriées et une transformation de la conscience individuelle peuvent réinventer la société.

La figure centrale est Stewart Brand. Ancien soldat, ancien étudiant en biologie à Stanford, ancien proche de Ken Kesey et des Merry Pranksters (les performances psychédéliques des Acid Tests), Brand publie en 1968 le *Whole Earth Catalog*. C'est un catalogue d'outils : graines, manuels, livres de Wiener et de Buckminster Fuller, plans de yourtes, panneaux solaires. Sa devise célèbre, « access to tools », signifie : nous pouvons nous émanciper en accédant directement aux outils, sans passer par les institutions. Steve Jobs, dans son discours de Stanford en 2005, décrira ce catalogue comme « la Bible de ma génération » et le précurseur de Google.

« Nous sommes comme des dieux, autant le faire bien. » — Stewart Brand, *Whole Earth Catalog*, 1968

La thèse de Turner est que cette contre-culture n'est pas une parenthèse romantique avant le triomphe du capitalisme numérique : elle EST l'origine idéologique de ce capitalisme. Les valeurs des New Communalists — décentralisation, horizontalité, autonomie individuelle, méfiance envers l'État, foi dans la technologie comme libératrice, communautés volontaires — deviennent le vocabulaire spontané de la Silicon Valley. Le Homebrew Computer Club, fondé en 1975 à Menlo Park, où Steve Wozniak présente le premier Apple, est directement issu de cette mouvance. La promesse du personal computer est libertaire avant d'être commerciale.

Contexte : pourquoi cette histoire compte

Pour des étudiants en sciences sociales, le moment californien des années 1970 est crucial parce qu'il défait l'opposition spontanée entre *technologie* et *contre-culture*. L'idéologie qui émerge alors — Fred Turner parle de **Californian Ideology** (terme repris et popularisé par Richard Barbrook et Andy Cameron en 1995) — combine libertarisme anti-étatique, foi technologique, individualisme expressif et économie de marché. Cette idéologie structure encore aujourd'hui le discours des entrepreneurs de l'IA, de Sam Altman à Elon Musk. Comprendre les LLMs, c'est aussi comprendre que leurs créateurs se pensent dans une lignée historique précise — qu'ils en aient conscience ou non.

2.4. Les systèmes experts : promesse et désillusion (1980–1987)

Entre temps, l'IA symbolique connaît un dernier moment de gloire : les systèmes experts. L'idée est simple : faire appel à des spécialistes humains, extraire leur connaissance sous forme de règles SI-ALORS, et la coder dans un système. MYCIN (1976) diagnostique les infections sanguines, XCON configure des ordinateurs DEC. Une véritable industrie se développe ; le Japon lance en 1982 le projet « Cinquième génération » avec 850 millions de dollars d'investissement public.

L'effondrement vient en 1987. Les systèmes experts sont fragiles : ils ne savent pas généraliser, ils dépendent d'experts coûteux pour formaliser leur savoir, ils ne savent pas apprendre. Surtout, l'arrivée des stations de travail Sun et des PC bon marché tue le marché des machines Lisp dédiées. Deuxième hiver de l'IA. Les chercheurs de l'IA changent souvent de discipline ou cachent qu'ils en font.

2.5. Bilan : deux héritages

La période 1960-1980 lègue à l'IA contemporaine deux héritages contradictoires. D'une part, l'échec de l'IA symbolique a montré qu'on ne pouvait pas réduire l'intelligence à des règles explicites — leçon qui sera redécouverte douloureusement après que les approches connexionnistes auront été ignorées pendant trois décennies. D'autre part, la rencontre entre cybernétique, contre-culture et personal computing a produit une matrice idéologique qui structure encore le discours de l'industrie : la technologie comme outil d'émancipation, l'horizontalité comme valeur, l'État comme obstacle.

Lectures recommandées pour la séance 2

- Turner, Fred (2012 [2006]), *Aux sources de l'utopie numérique. De la contre-culture à la cyberculture*, C&F Éditions.
- Markoff, John (2005), *What the Dormouse Said: How the Sixties Counterculture Shaped the Personal Computer Industry*, Viking.

- Dreyfus, Hubert (1984 [1972]), *Intelligence artificielle : mythes et limites*, Flammarion.
- Weizenbaum, Joseph (1976), *Computer Power and Human Reason*, W.H. Freeman.
- Barbrook, Richard et Cameron, Andy (1995), « The Californian Ideology », *Mute Magazine*.

Séance 3 — Le retour des réseaux de neurones

Connexionnisme, deep learning, capitalisme de surveillance (1980–2017)

3.1. La résurgence connexionniste : le perceptron et au-delà

Pour comprendre la révolution actuelle, il faut revenir en arrière. En 1958, Frank Rosenblatt invente le perceptron : un réseau de neurones formels capable d'apprendre à classer des images simples. La presse américaine s'enflamme, le New York Times annonce que le Pentagone a créé une machine qui « apprendra à marcher, parler, voir, écrire ».

En 1969, Marvin Minsky et Seymour Papert publient *Perceptrons*, un livre mathématiquement rigoureux qui démontre les limites du perceptron à une seule couche : il ne peut pas apprendre certaines fonctions logiques élémentaires (le XOR). Le livre est interprété, à tort selon plusieurs historiens, comme un acte de mort des réseaux de neurones. Le financement public se déplace vers l'IA symbolique. Les connexionnistes — Geoffrey Hinton, Yann LeCun, David Rumelhart — travaillent dans l'ombre pendant deux décennies.

La résurgence vient en 1986. Rumelhart, Hinton et Williams republient un algorithme déjà connu mais sous-exploité : la rétropropagation du gradient. C'est lui qui permet d'entraîner des réseaux à plusieurs couches, dépassant la limite de Minsky-Papert. Yann LeCun, à AT&T Bell Labs, l'applique en 1989 à la reconnaissance de chiffres manuscrits sur les chèques bancaires : le succès est tel qu'AT&T en équipe ses systèmes commerciaux à la fin des années 1990, traitant 10 à 20 % des chèques américains.

Concept technique : qu'est-ce qu'un réseau de neurones ?

Imaginons un réseau qui doit reconnaître des chats sur des photos. Il est constitué de couches d'unités élémentaires (les « neurones » formels). La première couche reçoit les pixels de l'image. Chaque neurone calcule une somme pondérée de ses entrées et applique une fonction de seuil. Ses sorties servent d'entrées à la couche suivante, et ainsi de suite jusqu'à la dernière couche, qui dit oui ou non.

Le réseau apprend en ajustant ses poids — les coefficients qui pondèrent les entrées de chaque neurone. On lui montre des milliers d'images étiquetées (« chat » / « pas chat »), il fait des prédictions, on calcule l'erreur, et la rétropropagation distribue cette erreur en arrière dans le réseau pour ajuster chaque poids. Après des millions d'itérations, le réseau converge vers une configuration qui reconnaît les chats — sans qu'on ait jamais codé explicitement ce qu'est un chat.

C'est une rupture épistémologique fondamentale par rapport à l'IA symbolique. Le réseau n'a pas de règles. Il a appris, par expérience statistique, à associer des configurations de pixels à des

étiquettes. Personne ne peut dire exactement pourquoi il classe telle image en chat. C'est ce qu'on appelle l'opacité (ou la « boîte noire ») de l'apprentissage profond.

3.2. La révolution de 2012 : ImageNet et le deep learning

Trois conditions doivent se réunir pour que les réseaux de neurones triomphent. Il faut beaucoup de données étiquetées pour les entraîner ; il faut une puissance de calcul massive ; il faut des algorithmes améliorés. Ces trois conditions convergent autour de 2012.

Les données : Fei-Fei Li, chercheuse à Stanford, lance en 2009 ImageNet, une base de 14 millions d'images étiquetées par des travailleurs précaires sur Amazon Mechanical Turk — la plateforme de microtâches lancée par Amazon en 2005. Ce point est sociologiquement crucial et nous y reviendrons : le « miracle » du deep learning repose sur du travail humain massif, sous-payé, invisibilisé.

Le calcul : les GPU (cartes graphiques), conçues à l'origine pour les jeux vidéo, se révèlent idéales pour les calculs matriciels qui sont le cœur des réseaux de neurones. NVIDIA, qui devient la firme la plus chère du monde dans les années 2020, doit sa fortune à cette convergence.

L'événement déclencheur a lieu en septembre 2012 lors du concours ImageNet. AlexNet, un réseau de neurones convolutifs développé par Alex Krizhevsky, Ilya Sutskever et Geoffrey Hinton à l'université de Toronto, divise par deux le taux d'erreur du meilleur système précédent. La communauté est choquée : en quelques mois, toute la recherche en vision par ordinateur bascule vers le deep learning. Google, Facebook, Microsoft recrutent massivement les chercheurs connexionnistes ; Geoffrey Hinton est embauché par Google en 2013, Yann LeCun par Facebook en 2013.

3.3. AlphaGo et l'apprentissage par renforcement (2016)

En mars 2016, AlphaGo, développé par DeepMind (filiale de Google), bat Lee Sedol, champion mondial du jeu de go, par 4 victoires à 1. Le go était considéré comme la dernière forteresse de l'intelligence humaine — son arbre de possibilités est tel qu'aucune approche par force brute ne peut fonctionner. Le programme combine apprentissage profond et apprentissage par renforcement (le réseau joue contre lui-même des millions de parties et apprend de ses victoires et défaites). Le coup 37 de la deuxième partie d'AlphaGo, jugé d'abord absurde par les commentateurs puis reconnu comme génial, devient un moment culturel : les machines peuvent désormais inventer des coups que les humains n'auraient pas imaginés.

3.4. Le tournant économique : capitalisme de surveillance et travail du clic

Cette section est centrale pour des étudiants en sciences sociales. Le triomphe du deep learning dans les années 2010 ne s'explique pas seulement par des progrès techniques. Il s'inscrit dans une transformation économique majeure que la sociologue Shoshana Zuboff a appelée le capitalisme de surveillance dans son ouvrage *L'Âge du capitalisme de surveillance* (2019, traduit 2020).

Sa thèse, brièvement : Google découvre vers 2002 que les traces que laissent les utilisateurs (clics, recherches, temps passé sur les pages) ne sont pas seulement utiles à améliorer le service ; elles constituent un surplus comportemental dont on peut prédire les comportements futurs et vendre ces prédictions à des annonceurs. Cette « réquisition de l'expérience humaine comme matière première » est le carburant de l'économie numérique. Or, ce surplus comportemental est précisément ce qui entraîne les modèles d'IA. Sans Gmail, YouTube, Facebook, sans des décennies d'extraction de données, le deep learning n'aurait rien sur quoi s'entraîner.

Cette extraction se double d'un travail invisible : celui des « micro-travailleurs du clic » que la sociologue Antonio Casilli a documenté dans *En attendant les robots* (2019). Pour qu'une IA reconnaisse des images, il faut que des humains aient préalablement étiqueté ces images. Pour qu'une IA modère les contenus, il faut des humains qui visionnent les pires contenus de l'internet. Ce travail est massivement délocalisé — au Kenya, aux Philippines, à Madagascar, au Venezuela —, payé quelques centimes la tâche, et systématiquement invisibilisé par le récit du « miracle de l'IA ».

Contexte critique : pourquoi parler d'extraction

La métaphore de l'extraction est volontaire et politique. Comme l'a montré la chercheuse Kate Crawford dans *Atlas of AI* (2021), l'IA contemporaine repose sur trois extractions massives : extraction de données (vie numérique des utilisateurs), extraction de travail (étiquetage, modération, supervision), et extraction de ressources matérielles (lithium pour les batteries, terres rares, eau pour refroidir les centres de calcul, électricité). L'IA n'est pas immatérielle : c'est une industrie lourde, géographiquement située, qui produit ses propres dégâts environnementaux et sociaux.

3.5. Bilan : la nouvelle matrice

Vers 2017, plusieurs choses sont en place. Sur le plan technique, le deep learning a démontré son efficacité sur la vision et la reconnaissance vocale. Sur le plan industriel, une poignée d'entreprises (Google, Facebook, Microsoft, Amazon, Apple) concentrent les talents, les données et le capital. Sur le plan géopolitique, la Chine émerge comme rivale, avec ses propres champions (Baidu, Alibaba, Tencent) et un État qui investit massivement dans l'IA. Sur le plan idéologique, le récit de l'« inéluctabilité » de l'IA s'installe : on ne discute plus si elle vient, on discute comment s'y adapter.

C'est ce contexte qui rend possible la révolution suivante, celle des Transformers et des grands modèles de langage.

Lectures recommandées pour la séance 3

- Zuboff, Shoshana (2020 [2019]), L'Âge du capitalisme de surveillance, Zulma.
- Casilli, Antonio (2019), En attendant les robots. Enquête sur le travail du clic, Seuil.
- Crawford, Kate (2021), Atlas of AI, Yale University Press.
- LeCun, Yann (2019), Quand la machine apprend, Odile Jacob (vulgarisation par un acteur central).
- Cardon, Dominique, Cointet, Jean-Philippe et Mazières, Antoine (2018), « La revanche des neurones », Réseaux, n° 211 (article de référence en français).

Séance 4 — Les LLMs

Comment ça marche, et qu'est-ce que ça nous dit (2017–aujourd'hui)

4.1. 2017 : le Transformer

En juin 2017, huit chercheurs de Google publient un article intitulé « Attention Is All You Need ». L'article est devenu l'un des plus cités de l'histoire de l'IA. Il propose une nouvelle architecture de réseau de neurones, le Transformer, qui va supplanter toutes les autres approches en traitement automatique des langues.

Pour comprendre l'enjeu, il faut savoir ce qu'on faisait avant. Les modèles de langage précédents (réseaux récurrents, LSTM) lisaient le texte mot par mot, séquentiellement, en gardant une mémoire interne. Cela posait deux problèmes : c'était lent (impossible à paralléliser) et la mémoire à long terme était mauvaise. Le Transformer remplace cette lecture séquentielle par un mécanisme d'attention qui permet à chaque mot d'une phrase de « regarder » directement tous les autres mots, et de pondérer leur importance pour son interprétation.

Concept technique : le mécanisme d'attention, intuition

Considérons la phrase : « Le chat dort sur le tapis parce qu'il est confortable ». À quoi se réfère « il » ? Au chat ou au tapis ? Notre cerveau résout cette ambiguïté instantanément en mobilisant le contexte : un tapis peut être confortable, un chat ne peut pas être confortable au sens propre dans cette construction. Le mécanisme d'attention fait quelque chose d'analogue : pour chaque mot de la phrase, il calcule à quels autres mots il doit prêter attention pour être correctement interprété.

Techniquement, chaque mot est représenté par un vecteur (une liste de nombres), et l'attention est une moyenne pondérée des vecteurs des autres mots, où les poids sont calculés dynamiquement. C'est cette opération, répétée des dizaines de fois sur des couches successives, qui produit la représentation finale du texte.

4.2. Les briques fondamentales : tokens, embeddings, attention

Comprendre un LLM exige de comprendre trois concepts élémentaires.

Premier concept : les tokens. Un LLM ne voit pas des mots. Il voit des tokens, qui sont des fragments de texte — parfois un mot complet, parfois une syllabe, parfois quelques caractères. Le mot « anticonstitutionnellement » sera découpé en plusieurs tokens, tandis que « le » est un token unique. Cette tokenisation a des effets politiques : les langues occidentales, sur lesquelles les modèles ont été principalement entraînés, sont mieux découpées que les langues à morphologie complexe ou à écriture non-latine, ce qui produit des inégalités de performance entre langues.

Deuxième concept : les embeddings (plongements). Chaque token est converti en un vecteur de plusieurs centaines ou milliers de nombres. Cet espace vectoriel a une propriété remarquable : les mots de sens proche se retrouvent dans des régions proches de l'espace. L'exemple classique : $vec(roi) - vec(homme) + vec(femme) \approx vec(reine)$. Le modèle a appris, à partir des co-occurrences statistiques dans son corpus, une géométrie du sens — qui est aussi, comme l'ont montré de nombreux travaux, une géométrie des biais sociaux du corpus.

Troisième concept : l'attention. Comme expliqué plus haut, c'est le mécanisme qui permet à chaque token de mobiliser le contexte. Un Transformer empile typiquement plusieurs dizaines de couches d'attention, chacune raffinant la représentation de chaque token en fonction de l'ensemble du texte.

4.3. Comment un LLM est entraîné

Un LLM apprend par une tâche apparemment triviale : prédire le prochain token. On lui donne un fragment de texte (par exemple : « Le chat dort sur le ») et on lui demande de prédire le prochain token (probablement « tapis » ou « canapé »). Cette tâche, répétée sur des milliards de fragments tirés d'internet, force le modèle à apprendre la grammaire, la sémantique, les structures argumentatives, les connaissances factuelles encodées dans ces textes.

L'entraînement procède en plusieurs phases. Le pré-entraînement consiste à exposer le modèle à un corpus massif (CommonCrawl, Wikipedia, livres numérisés, code informatique, etc.) en lui faisant accomplir cette tâche de prédiction. C'est là que se construisent les capacités linguistiques fondamentales. Pour les modèles les plus récents (GPT-4, Claude, Gemini), ce corpus représente plusieurs milliers de milliards de tokens — l'équivalent de plusieurs vies humaines de lecture.

Vient ensuite le fine-tuning supervisé, où des humains rédigent des exemples de bons dialogues pour que le modèle apprenne à se comporter en assistant. Puis le RLHF (Reinforcement Learning from Human Feedback) : des humains comparent deux réponses du modèle et indiquent laquelle est meilleure ; ces préférences entraînent un « modèle de récompense » qui guide ensuite le modèle principal vers des réponses plus utiles, plus honnêtes, moins toxiques. Le RLHF est ce qui distingue un LLM brut (qui complète n'importe quel texte sans contrainte) d'un assistant comme ChatGPT (qui refuse certaines demandes, adopte un ton coopératif, etc.).

Contexte critique : qui sont les évaluateurs ?

Le RLHF repose sur des évaluateurs humains. Une enquête du *Time* en janvier 2023 a révélé qu'OpenAI sous-traitait à la firme Sama des travailleurs kenyans payés moins de 2 dollars de l'heure pour étiqueter des contenus extrêmement toxiques (violences, agressions sexuelles sur enfants, etc.) qui devaient être filtrés du modèle. Plusieurs travailleurs ont rapporté des traumatismes psychologiques durables. La « moralisation » des LLMs occidentaux est ainsi

externalisée vers des suds globaux à bas coûts. C'est une dimension fondamentale du fonctionnement réel de ces systèmes, que le récit officiel de l'industrie occulte systématiquement.

4.4. Émergence et lois d'échelle

L'un des résultats les plus troublants des dernières années est ce qu'on appelle les lois d'échelle. À partir d'environ 2020, on observe que les capacités d'un modèle augmentent de manière prévisible avec sa taille (nombre de paramètres), la quantité de données et la puissance de calcul utilisée. Plus encore, certaines capacités semblent émerger brutalement à partir d'une certaine échelle : un modèle de 1 milliard de paramètres ne sait pas faire d'arithmétique à plusieurs chiffres, un modèle de 100 milliards de paramètres y parvient. Ce phénomène d'émergence est mal compris théoriquement et fait l'objet de débats intenses dans la recherche.

Sur le plan industriel, ces lois d'échelle ont une conséquence majeure : la course aux gros modèles est devenue une course au capital. Entraîner un modèle de la taille de GPT-4 coûte plusieurs centaines de millions de dollars (entre 100 et 200 millions selon les estimations publiques). Seules une dizaine d'entreprises au monde peuvent se le permettre. La concentration oligopolistique de l'industrie — OpenAI, Anthropic, Google DeepMind, Meta, xAI, Mistral en Europe, DeepSeek et Alibaba en Chine — est une conséquence directe de ces lois d'échelle.

4.5. Critique des LLMs : trois entrées

4.5.1. La critique technique : « perroquets stochastiques »

En 2021, l'article « On the Dangers of Stochastic Parrots » signé notamment par Emily Bender, Timnit Gebru, Angelina McMillan-Major et Margaret Mitchell devient une référence. Les autrices y développent plusieurs thèses : (1) les LLMs ne comprennent pas ce qu'ils disent, ils produisent des séquences statistiquement plausibles de tokens ; (2) leur entraînement consomme des quantités d'énergie colossales avec un impact carbone massif ; (3) leur corpus, principalement issu d'internet, encode des biais (sexisme, racisme, eurocentrisme) qu'ils reproduisent et amplifient ; (4) leur production de texte plausible mais infondé (« hallucinations ») pose des problèmes éthiques et démocratiques majeurs. La publication de cet article a coûté à Timnit Gebru son poste chez Google.

4.5.2. La critique politique : concentration et pouvoir

Plusieurs chercheurs (Cécile Digue, Asma Mhalla, Yann Moulier-Boutang, Sarah Myers West) soulignent que les LLMs intensifient une dynamique déjà présente : la concentration du pouvoir économique, technologique et politique entre quelques firmes. Ces firmes deviennent des acteurs géopolitiques de premier plan, capables d'influer sur les processus démocratiques (modération des plateformes, sélection des informations, production massive de contenus). La régulation peine à

suivre : l'AI Act européen, adopté en 2024, est la première tentative sérieuse mais ses effets restent à mesurer. La question politique centrale n'est plus « les machines vont-elles nous dépasser ? » mais « qui contrôle les machines, et selon quels critères ? ».

4.5.3. La critique épistémologique : que devient le savoir ?

Une troisième critique, plus philosophique, concerne le statut de la connaissance. Les LLMs produisent un discours qui ressemble à une connaissance experte mais qui est, en réalité, une moyenne probabiliste de discours. Pour des disciplines qui, comme les sciences sociales, valorisent la position énonciative, le contexte, la singularité de l'enquête, cette automatisation pose des questions inédites. Que devient le travail intellectuel quand on peut générer en quelques secondes un texte cohérent sur n'importe quel sujet ? Quelle est la valeur de la lecture profonde, du commentaire, de l'écriture, dans un monde où ces opérations peuvent être simulées ? Ces questions ne sont pas des questions techniques ; ce sont des questions de civilisation que les sciences sociales ont vocation à traiter.

4.6. Conclusion : pour un usage critique des LLMs

Au terme de ce parcours, plusieurs idées doivent rester. L'IA n'est pas une technologie neutre : elle hérite d'une histoire militaire, capitaliste et culturelle qui structure ce qu'elle est et ce qu'elle peut. Les LLMs, en particulier, sont l'aboutissement d'une longue histoire qui croise la cybernétique, le connexionnisme, la contre-culture californienne, le capitalisme de surveillance et la concentration du capital de calcul.

Cela ne signifie pas qu'il faille rejeter ces technologies en bloc. Cela signifie qu'il faut développer une compétence critique : savoir ce qu'elles sont, ce qu'elles ne sont pas, à qui elles profitent, quels travaux et quelles ressources elles mobilisent, quelles questions elles laissent ouvertes. Cette compétence est précisément celle que les sciences sociales sont en mesure d'apporter au débat public — à condition de ne pas céder ni à la fascination technophile ni au rejet réactif.

« Une nouvelle technologie n'est pas additive ; elle est écologique. Elle change tout. » — Neil Postman, *Technopoly*, 1992

Lectures recommandées pour la séance 4

- Bender, Emily M., Gebru, Timnit, McMillan-Major, Angelina et Mitchell, Margaret (2021), « On the Dangers of Stochastic Parrots », FAccT '21 (article librement accessible).
- Mhalla, Asma (2024), *Technopolitique. Comment la technologie fait de nous des soldats*, Seuil.
- Cardon, Dominique (2019), *Culture numérique*, Presses de Sciences Po.

- Pasquinelli, Matteo (2023), *The Eye of the Master: A Social History of Artificial Intelligence*, Verso.
- Vaswani, Ashish et al. (2017), « Attention Is All You Need », NeurIPS (article fondateur, technique mais accessible avec quelques explications).

Annexe — Chronologie de référence

Date	Événement
1936	Alan Turing publie « On Computable Numbers » : la machine de Turing.
1943	McCulloch et Pitts publient leur modèle de neurone formel.
1946–53	Conférences Macy à New York : naissance de la cybernétique.
1948	Wiener publie Cybernetics ; Shannon publie sa théorie de l'information.
1950	Turing publie « Computing Machinery and Intelligence » (le test de Turing).
1956	Séminaire de Dartmouth : naissance officielle du terme « intelligence artificielle ».
1958	Frank Rosenblatt invente le perceptron.
1965	Hubert Dreyfus, <i>Alchemy and AI</i> : première grande critique philosophique.
1966	Joseph Weizenbaum développe Eliza.
1968	Stewart Brand publie le Whole Earth Catalog.
1969	Minsky et Papert, <i>Perceptrons</i> : les réseaux de neurones tombent en disgrâce.
1974	Rapport Lighthill : premier hiver de l'IA.
1975	Fondation du Homebrew Computer Club.
1976	Weizenbaum, <i>Computer Power and Human Reason</i> .
1986	Rumelhart, Hinton et Williams : la rétropropagation relance les réseaux de neurones.
1987	Effondrement des systèmes experts : second hiver de l'IA.
1989	Yann LeCun applique les réseaux convolutifs à la reconnaissance de chiffres.
1995	Barbrook et Cameron, « The Californian Ideology ».
2005	Lancement d'Amazon Mechanical Turk.
2009	Fei-Fei Li lance la base de données ImageNet.
2012	AlexNet remporte ImageNet : début de l'ère du deep learning.
2016	AlphaGo bat Lee Sedol au go (4–1).
2017	Google publie « Attention Is All You Need » : naissance du Transformer.
2019	Casilli, <i>En attendant les robots</i> ; Zuboff, <i>L'Âge du capitalisme de surveillance</i> .
2020	OpenAI publie GPT-3 (175 milliards de paramètres).
2021	Bender, Gebru et al. : « On the Dangers of Stochastic Parrots ».

2022	Lancement public de ChatGPT (novembre).
2023	Enquête Time sur les travailleurs kenyans étiqueteurs d'OpenAI ; GPT-4.
2024	Adoption de l'AI Act par l'Union européenne.